

Résumé Complet - Sémantique Vectorielle et Embeddings

I. Sémantique Lexicale (Sens des Mots)

Cette section explore la façon dont le sens des mots est traditionnellement défini.

Synonymie

- Deux mots sont considérés comme synonymes s'ils ont un sens identique ou très proche.
- La définition formelle implique la capacité de substituer un mot par l'autre dans n'importe quelle phrase sans modifier le sens général.
- En pratique, la synonymie est souvent approximative (ex: voiture, automobile), car le **principe de contraste** stipule qu'une différence dans la forme linguistique correspond toujours à une différence de sens.

Similarité

- La plupart des mots ont des mots similaires (ex: cat et dog).
- La notion de similarité est plus pertinente que la synonymie stricte pour les tâches sémantiques larges.
- Des ensembles de données (ex: **SimLex-999**) ont été créés à partir de jugements humains pour évaluer cette similarité.

Champs Sémantiques

- Les mots peuvent être liés par leur appartenance à un même **champ sémantique**, regroupant un ensemble de mots associés à un même domaine de signification (ex: chirurgien, infirmière pour les hôpitaux).
- Ce concept est lié aux **modèles thématiques** (comme le **Latent Dirichlet Allocation - LDA**).

II. Sémantique Vectorielle et Embeddings

La **Sémantique Vectorielle** est l'approche de référence pour représenter la signification des mots en TALN.

1. Principes et Types de Modèles

- Un bon modèle de sémantique vectorielle doit refléter diverses relations lexicales : synonymie, antonymie, similarité, connotation, et appartenance à un même champ sémantique.

Modèles basés sur la Connotation

- Représentent la signification par les émotions, jugements et évaluations associés au mot.
- Les mots varient selon trois dimensions principales :
 1. **Valence** (positivité)
 2. **Arousal** (intensité émotionnelle)
 3. **Dominance** (autorité)

- Chaque mot est représenté par un vecteur à trois dimensions (ses scores sur Valence, Arousal, Dominance).

Modèles basés sur la Distribution (Modèles Modernes)

- Reposent sur l'**Hypothèse Distributionnelle** : les mots apparaissant dans des contextes similaires ont des significations proches.
- Chaque mot est représenté par un point/vecteur dans un espace sémantique multidimensionnel.
- Ces représentations vectorielles sont appelées **Embeddings** (terme souvent réservé aux vecteurs denses).
- Ils permettent la généralisation dans des tâches comme l'analyse des sentiments.

2. Familles de Modèles Distributionnels

La sémantique vectorielle distributionnelle se divise en deux familles principales :

Famille	Caractéristiques	Exemples
Modèles basés sur la Co-occurrence	Vecteurs longs et creux (sparse), basés sur les fréquences de mots voisins	TF-IDF, PPMI
Modèles basés sur l'Apprentissage	Vecteurs courts et denses, capables de capturer directement les relations sémantiques	Word2vec

3. Modèles de Co-occurrence Détaillés

TF-IDF (Term Frequency – Inverse Document Frequency)

- Utilise une **Matrice Terme-Document** où chaque mot est un vecteur dont les dimensions sont les documents du corpus.
- La pondération **TF-IDF** est utilisée pour surmonter le problème des fréquences brutes (où les mots très fréquents comme *good* dominant sans être informatifs).
 - **TF** : Fréquence du terme dans le document, souvent transformée par un logarithme pour atténuer l'impact des hautes fréquences :

$$[\text{TF}] = \log_{10}(\text{count}(t, d) + 1)$$
 - **IDF** : Fréquence Inverse des Documents, attribue un poids plus important aux termes rares (distinctifs) qui n'apparaissent que dans un nombre limité de documents. La transformation logarithmique est utilisée.

PPMI (Positive Pointwise Mutual Information)

- Utilise une **Matrice Terme-Terme** (ou Mot-Mot) où chaque mot est un vecteur dont les dimensions sont les autres mots du vocabulaire.
- Les dimensions représentent la fréquence de co-occurrence dans une fenêtre contextuelle.
- La **PPMI** est utilisée pour valoriser les co-occurrences réellement informatives, contrairement aux fréquences brutes qui favorisent les mots fréquents.
 - **PMI** : Mesure si deux mots apparaissent ensemble plus souvent que par hasard. Les valeurs négatives sont généralement ignorées.
 - **PPMI** : Défini comme $[\text{PPMI}] = \max(\text{PMI}, 0)$

III. Mesure de Similarité

Similarité Cosinus

- C'est la métrique la plus couramment utilisée en TALN pour mesurer la similarité entre deux mots représentés par leurs vecteurs d'embedding.
- Elle mesure l'**angle entre les deux vecteurs** : plus l'angle est petit, plus les mots sont similaires.
- Elle est préférée au produit scalaire brut car ce dernier favorise les mots fréquents (qui ont des vecteurs plus longs).
- La similarité cosinus est le produit scalaire normalisé par la longueur des vecteurs :
$$\text{cos}(v, w) = \frac{v \cdot w}{\|v\| \|w\|} = \frac{\sum_{i=1}^d v_i w_i}{\sqrt{\sum_{i=1}^d (v_i)^2} \sqrt{\sum_{i=1}^d (w_i)^2}}$$