

Séance N° 2 - Modèles de Sémantique Vectorielle et Skip-Gram (Word2Vec)

1. Modèles de Sémantique Vectorielle

La sémantique vectorielle cherche à représenter la signification des mots dans un espace multidimensionnel.

A. Modèles Fondamentaux

- **Modèles basés sur la Connotation** : La signification est représentée par les connotations du mot.
- **Modèles basés sur la Distribution** : La signification est dérivée de la distribution. **L'Hypothèse Distributionnelle** stipule que les mots apparaissant dans des contextes similaires ont des significations proches.

B. Familles de Modèles Distributionnels

Famille de Modèles	Caractéristiques	Vecteurs	Exemples
Co-occurrence	Représentent la signification à partir des fréquences des mots voisins (co-occurrence).	Longs et Creux (sparse) . Dimensions : documents (matrice Terme-Document, pondérée TF-IDF) ou mots (matrice Terme-Terme, pondérée PPMI).	TF-IDF, PPMI
Apprentissage	Apprennent directement des représentations vectorielles (Embeddings) qui capturent les relations sémantiques.	Courts et Denses . Dimension d (50 à 1000) est beaucoup plus petite que la taille du vocabulaire V .	Word2vec (Skip-Gram)

C. Avantages des Embeddings Denses (vs. Creux)

Les Word Embeddings sont des vecteurs courts et denses qui sont généralement plus efficaces pour les tâches de TALN :

- **Efficacité** : Ils contiennent des valeurs réelles, y compris négatives.
- **Généralisation** : L'espace des paramètres est réduit (ex: 300 dimensions vs. 50 000 dimensions pour les vecteurs creux), ce qui facilite la généralisation et aide à éviter le surapprentissage.
- **Sémantique** : Les vecteurs denses peuvent mieux capturer les relations de synonymie, car les dimensions associées aux synonymes ne sont pas distinctes.

2. Skip-Gram avec Échantillonnage Négatif (SGNS)

Skip-Gram (souvent appelé SGNS) est un algorithme de word2vec utilisé pour générer des embeddings de mots statiques (un embedding fixe par mot).

A. Principe

- Skip-Gram reformule l'apprentissage de la sémantique comme une tâche de **classification binaire** : prédire si un mot $\mathbf{c}$ a une forte probabilité d'apparaître près du mot cible $\mathbf{w}$.
- **Objectif Principal** : Le véritable objectif n'est pas la classification, mais d'apprendre les poids du classifieur, car ces poids constituent directement les embeddings de mots.

B. Génération des Données d'Entraînement

Le modèle utilise le texte brut pour générer des données auto-supervisées (sans étiquetage manuel).

- **Exemples Positifs (Label 1)** : Une paire $(\mathbf{w}, \mathbf{c})$ est positive si $\mathbf{c}$ est un mot de contexte réel trouvé dans la fenêtre de voisinage du mot cible $\mathbf{w}$.
- **Échantillonnage Négatif** : Pour chaque exemple positif, le modèle génère k échantillons négatifs $(\mathbf{w}, \mathbf{c}_{neg})$.
 - Le mot de bruit $\mathbf{c}_{neg}$ est choisi aléatoirement dans le vocabulaire (à l'exception de $\mathbf{w}$ et $\mathbf{c}$).
 - Les mots de bruit sont échantillonnés selon une distribution Unigramme pondérée $P_{\alpha}(\mathbf{w})$ avec $\alpha = 0.75$. Cette pondération augmente légèrement la probabilité de sélectionner des mots rares comme mots de bruit, améliorant les performances.

C. Calcul de Probabilité et Embeddings

Le modèle utilise la similarité entre les embeddings (produit scalaire) pour estimer la probabilité de co-occurrence.

- **Similarité** : $\text{similarity}(\mathbf{w}, \mathbf{c}) \approx \mathbf{c} \cdot \mathbf{w}$
- **Probabilité** : La fonction Sigmoid (σ) est appliquée au produit scalaire pour obtenir une probabilité :

$$P^+(\mathbf{w}, \mathbf{c}) = \sigma(\mathbf{c} \cdot \mathbf{w}) = \frac{1}{1 + \exp(-\mathbf{c} \cdot \mathbf{w})}$$

D. Paramètres du Modèle

Skip-Gram maintient deux types d'embeddings pour chaque mot i :

- Un vecteur d'embedding cible $\mathbf{w}_i$ (matrice $\mathbf{W}$).
- Un vecteur d'embedding contexte $\mathbf{c}_i$ (matrice $\mathbf{C}$).
- Après l'entraînement, le mot i est représenté uniquement par son embedding cible $\mathbf{w}_i$.

E. Apprentissage (Descente de Gradient)

L'apprentissage se fait par **Descente de Gradient Stochastique (SGD)** en minimisant la fonction de perte L_{CE} . L'objectif est :

- Maximiser la similarité entre le vecteur du mot cible $\mathbf{w}$ et les vecteurs de contexte réels $\mathbf{c}_{\text{pos}}$ (les rapprocher).
- Minimiser la similarité entre le vecteur du mot cible $\mathbf{w}$ et les k mots de bruit $\mathbf{c}_{\text{neg}}$ (les éloigner).

La fonction de perte pour un exemple positif et ses k exemples négatifs est :

$$L_{\text{CE}} = -\log P^+(\mathbf{w}, \mathbf{c}_{\text{pos}}) - \sum_{i=1}^k \log P^-(\mathbf{w}, \mathbf{c}_{\text{neg}_i})$$

(où $P^-(\mathbf{w}, \mathbf{c}) = 1 - P^+(\mathbf{w}, \mathbf{c})$)

La taille de la fenêtre contextuelle L est un paramètre important qui doit être ajusté pour optimiser les performances.